

# PPGBG 数据集文档

**数据集名称:** PPGBG  
**版本:** v1.0  
**发布目录:** PPGBG\_v1.0\_release/  
**申请联系邮箱:** PPGBGa@163.com  
**引用要求:** 使用 PPGBG 的成果须引用关联论文。本版本未设置单独的数据集 DOI。

本文档说明 PPGBG 的文件内容、数据结构、变量定义、采集流程摘要、适用研究场景和已知局限。PPGBG 的访问和使用受 PPGBG 数据使用协议约束。

## 1. 概述

PPGBG 是一个面向指尖光电容积脉搏波（photoplethysmography, PPG）无创血糖估计的纵向、跨受试者基准数据集。数据集包含同步袖带血压测量结果和临床元数据，可用于重复测量 encounter 级评估、分布漂移分析、增量学习或持续学习研究，以及无袖带血压分析等辅助任务。

| 项目             | 数值                               |
|----------------|----------------------------------|
| 受试者            | 183 名（男 112 名，女 71 名）            |
| 临床 encounter   | 528 次                            |
| 有效 40 s PPG 采集 | 523 次                            |
| 有效 4 s PPG 窗口  | 5,224 个                          |
| 信号             | 指尖 PPG，1000 Hz，4 s 窗口（4000 个采样点） |
| 参考血糖           | 指尖毛细血管血糖（mmol/L）                 |
| 血压             | 袖带 SBP/DBP（mmHg）                 |
| 采集跨度           | 285 天                            |
| 标签形式           | encounter 级临床测量值和受试者级人口学/合并症信息   |

## 2. 压缩包文件结构

```
PPGBG_v1.0_release/  
|-- data/  
|   |-- signals.npy           # float32 数组，形状为 (5224, 4000); PPG 窗口  
|   |-- windows.csv          # 5224 行；每行对应一个 PPG 窗口  
|   |-- encounters.csv       # 528 行；每行对应一次临床 encounter  
|   |-- subjects.csv         # 183 行；每行对应一名受试者  
|-- documents/  
|   |-- en/                  # 英文 PDF 文档  
|   |-- zh/                  # 中文 PDF 文档  
|-- SHA256SUMS.txt           # 发布文件的 SHA-256 校验值
```

**信号与表格对应关系：**data/signals.npy 的第 i 行对应 data/windows.csv 的第 i 行。windows.csv 中的 window\_id、subject\_id 和 encounter\_id 字段提供窗口、临床 encounter 与受试者之间的索引关系。

### 3. 信号格式

- **形状：**(5224, 4000)。
- **数据类型：**float32。
- **采样率：**1000 Hz。
- **窗口长度：**每行 4 s，对应 4000 个采样点。
- **分割方式：**从有效 40 s PPG 采集中切分得到非重叠 4 s 窗口。
- **预处理：**每个 4 s 窗口先使用零相位、前向-后向、四阶 Butterworth 带通滤波器处理，通带为 0.5-8 Hz；随后基于该窗口自身的均值和标准差进行 z-score 标准化。发布的数组已经是窗口级滤波和标准化后的形式。
- **其他处理：**发布数组未额外加入基线校正、运动伪影抑制、小波变换或去趋势处理。
- **采集与窗口关系：**一次有效 40 s 采集通常产生 10 个 4 s 窗口。6 次有效采集中各有 1 个短时平线窗口在整理过程中被移除，因此各保留 9 个窗口。

```
import numpy as np
import pandas as pd

X = np.load("data/signals.npy")
W = pd.read_csv("data/windows.csv")
y = W["bg"].to_numpy()
```

### 4. 标签字典

#### 4.1 windows.csv

| 字段           | 类型  | 单位/编码 | 说明                                       |
|--------------|-----|-------|------------------------------------------|
| window_id    | 字符串 | -     | 唯一窗口编号。                                  |
| subject_id   | 字符串 | -     | 受试者编号。                                   |
| encounter_id | 字符串 | -     | 临床 encounter 编号。                         |
| window_index | 整数  | -     | 窗口在对应 encounter 内的位置。                    |
| valid_40s    | 整数  | 0/1   | 来源 40 s 采集的硬件一致性指示；windows.csv 中所有行均为 1。 |

|                                                                                       |     |                   |                      |
|---------------------------------------------------------------------------------------|-----|-------------------|----------------------|
| sex                                                                                   | 字符串 | M/F               | 性别。                  |
| age                                                                                   | 整数  | 岁                 | encounter 时年龄。       |
| bmi                                                                                   | 浮点数 | kg/m <sup>2</sup> | 体质指数。                |
| weight                                                                                | 浮点数 | kg                | 体重。                  |
| height                                                                                | 浮点数 | m                 | 身高。                  |
| hr                                                                                    | 整数  | bpm               | 参考监护设备测得的心率。         |
| sbp, dbp                                                                              | 整数  | mmHg              | 收缩压和舒张压。             |
| bg                                                                                    | 浮点数 | mmol/L            | 参考指尖毛细血管血糖目标值。       |
| hypertension, diabetes, cvd, ckd                                                      | 整数  | 0/1               | 合并症指示变量。             |
| active_infection, active_fever,<br>active_postoperative, active_other,<br>active_none | 整数  | 0/1               | encounter 级急性状态指示变量。 |
| smoking_never, smoking_former, smoking_current                                        | 整数  | 0/1               | 吸烟状态指示变量。            |

## 4.2 encounters.csv

encounter\_id、subject\_id、encounter\_index、clinical\_encounter\_count、effective\_window\_count、valid\_40s、hr、sbp、dbp、bg。

每行代表一次临床 encounter。effective\_window\_count 表示该 encounter 保留的 4 s 窗口数量。本版本中，517 次 encounter 各有 10 个窗口，6 次 encounter 各有 9 个窗口，5 次 encounter 的 valid\_40s = 0 且保留窗口数为 0。保留窗口数为 0 的行用于记录纵向 encounter 信息，不对应 signals.npy 或 windows.csv 中的行。

## 4.3 subjects.csv

subject\_id、model\_group、model\_diabetic\_group、clinical\_encounters、valid\_40s\_acquisitions、final\_valid\_4s\_windows、sex、weight\_kg、height\_m、age\_years、bmi\_kg\_m2、hypertension、diabetes、cvd、ckd、active\_\*、smoking\_\*。

model\_group 和 model\_diabetic\_group 定义关联论文中使用的分析分层：39 名受试者属于 Diabetic 分析组，144 名受试者属于 Non-diabetic 分析组。该建模分组并不等同于临床 diabetes 合并症标志；临床 diabetes 标志为阳性的受试者为 57 名。

## 5. 队列统计

受试者级人口学变量基于 subjects.csv 计算。HR、SBP、DBP 和 BG 基于 encounters.csv 在 encounter 级计算。

| 指标           | 均值     | 最小值   | 最大值   | 标准差   |
|--------------|--------|-------|-------|-------|
| 体重 (kg)      | 69.76  | 46.30 | 98.00 | 10.93 |
| 身高 (m)       | 1.69   | 1.55  | 1.87  | 0.07  |
| 年龄 (岁)       | 57.02  | 21    | 96    | 21.20 |
| BMI (kg/m^2) | 24.35  | 16.80 | 33.51 | 3.20  |
| HR (bpm)     | 72.98  | 55    | 102   | 7.67  |
| SBP (mmHg)   | 130.02 | 85    | 164   | 18.57 |
| DBP (mmHg)   | 71.74  | 44    | 94    | 9.85  |
| BG (mmol/L)  | 6.56   | 4.2   | 16.3  | 2.12  |

基线合并症比例：高血压 55%，糖尿病 31%，心血管疾病 43%，慢性肾病 8%。吸烟状态比例：从不吸烟 43%，既往吸烟 26%，当前吸烟 31%。

## 6. 采集流程摘要

数据在开放环境协议下采集。受试者保持坐姿，手臂自然支撑。采集未设置禁食或用药限制，以保留个体内变化和实际测量条件。每次会话约 10 分钟，其中包含 5 分钟适应期。参考指尖毛细血管血糖和 PPG 均取自左手食指，血压由右上臂袖带设备测量。同一次 encounter 内各项测量在约 2 分钟时间窗内完成。

- 参考血糖：Accu-Chek Performa (Roche)，测量范围 0.6-33.3 mmol/L，每日进行 L1/L2 质量控制。
- 血压：Omron J751 上臂式血压计。
- PPG：EVAL-ADPD4100Z-PPG 开发板和 EVAL-ADPDUCZ MCU (Analog Devices)，采样率 1 kHz。

## 7. 数据整理流程

候选队列包含 195 名受试者。最终发布版本包含 183 名受试者和 5,224 个保留的 4 s PPG 窗口。

1. 完整性筛查移除 3 名标签无效或超出范围的受试者。
2. 可用性筛查移除 2 名存在采样率或时长问题的受试者。
3. 基于偏度的信号质量筛查移除 7 名低于队列平均信号质量阈值的受试者。
4. 将剩余有效 40 s 采集分割为非重叠 4 s 窗口。
5. 短时平线筛查移除 6 个单独窗口。

最终发布：183 名受试者、528 次临床 encounter、523 次有效 40 s 采集和 5,224 个有效 4 s 窗口。

## 8. 伦理与隐私

研究经参与临床机构的伦理委员会审查并批准。所有受试者均在数据采集前提供知情同意。发布数据不包含直接身份标识符，受试者仅以伪匿名编号表示。PPGBG 数据使用协议禁止任何再识别尝试。

## 9. 预期用途和支持任务

- 主要任务：跨受试者评估下基于 PPG 的无创血糖估计。
- 辅助任务：无袖带血压估计；纵向分布漂移下的增量学习或持续学习；超越单窗口指标的 encounter 级评估。
- 适用场景：非商业学术研究。
- 排除场景：临床诊断、治疗或真实患者医疗决策。

## 10. 已知局限

- 队列来自单中心，可能无法完全泛化到所有人群、采集设备或临床环境。
- 参考标签来自设备测量值，而非实验室静脉血检测。
- 发布的 PPG 信号已完成滤波和窗口标准化；v1.0 不分发原始 ADC 记录。
- 数据不发布精确时间戳，因此无法从发布文件中重新计算天级间隔。

## 11. 版权、许可和引用

版权：二〇二六年数据集贡献者。随附数据使用协议未明确授予的其他权利均予以保留。未经另行书面授权，禁止再分发、镜像或公开托管。

PPGBG 及其文档仅根据 PPGBG 数据使用协议提供。除该协议明确授权的权利外，不授予任何其他权利。未经数据提供方另行书面授权，禁止以任何形式对全部或部分数据进行再分发、镜像、转许可或公开托管。数据访问请求应发送至 PPGBGa@163.com。

使用 PPGBG 的成果须引用关联论文：

Zhang, Z., Li, J., Wang, Y., Yang, K., and Lei, T. (2026). Dynamic Incremental Learning for Non-invasive Blood Glucose Estimation from Wearable Physiological Signals. Manuscript under review. Preprint DOI: <https://doi.org/10.5281/zenodo.21202402>

```
@unpublished{zhang2026dil,  
  title = {Dynamic Incremental Learning for Non-invasive Blood Glucose Estimation from Wearable  
Physiological Signals},  
  author = {Zhang, Zexing and Li, Jichao and Wang, Yilong and Yang, Kewei and Lei, Tianyang},  
  year = {2026},  
  doi = {10.5281/zenodo.21202402},  
  note = {Manuscript under review; preprint on Zenodo}  
}
```

## 12. 访问申请

如需申请访问，请填写并签署 documents/en/DATA\_USE\_AGREEMENT.pdf 或 documents/zh/DATA\_USE\_AGREEMENT\_zh.pdf，并将签署后的协议发送至 PPGBGa@163.com。